

3. 직무별 역할 분담 및 To-Do (요구사항명세서 기반)

≡ 진행상황

사전준비

WBS/요구사항명세서 확인:

https://docs.google.com/spreadsheets/d/1nN2nSwnHpyBTmxKFuDQhWRdxryo2_LULo06Eq6hpOkc/edit?usp=sharing

※ 데이터 연동 방법: 본인 파트 로직을 당장 짤 때 필요한 더미 파일(Mock Data)은 이미 PM이 `data/` 폴더에 생성해 두었으니 아래 명시된 파일을 파이썬으로 불러와서 개발을 시작하면 됨.

[1번: 상진] - AI 구조화 및 API 통신망 구축 (STR 도메인)

- 담당 기능 ID: STR-01, STR-02, STR-03, STR-04, STR-05
- 사용할 데이터: `data/samples/sample_100_for_meeting.csv`
- To-Do:
 - 배치 구조화 API (STR-01): 검증된 프롬프트를 활용해 100건의 불만 CSV를 LLM API에 쓰고 JSON 파일 100개로 일괄 저장하는 로직 작성.
 - 스키마 확장 (STR-04): 출력 JSON에 `mentions_existing_recall` 플래그가 정상적으로 추가되어 나오는지 확인.
 - 환각 자동 검사 (STR-02): LLM이 뽑아낸 근거 인용문이 실제 원본 텍스트에 존재하는지 문자열을 대조하는 파이썬 검증 코드 작성.
 - 질문 이해 모듈 (STR-05): "투싼 계기판 깜빡임" 같은 단문 입력 시 차종과 증상을 추출해 내는 로직 구현.

[2번: 영운] - QA, 검사 AI (Judge) 설계 및 프롬프트 (JDG 도메인)

- 담당 기능 ID: JDG-01, JDG-02, JDG-03, JDG-04
- 사용할 데이터: `data/samples/sample_20_for_llm_test.csv` 및 `grading_sheet.csv`
- To-Do:
 - [중요] 교차 채점 이벤트 주관 (JDG-04): 팀원 전원 20건 독립 교차 채점 주관 및 결과(일치율) 취합 (아래 4번 가이드 참조).
 - 제약된 Judge (JDG-02): 검사 AI가 스키마와 규칙 내에서만 채점하고 원문에 없는 내용은 차단하도록 룰을 빡빡하게 주입한 프롬프트 설계.
 - Self-Consistency (JDG-01): 동일한 판단을 3~5회 시켜 다수결 처리하고, 불일치 시 '불확실' 플래그를 띄우는 판단 로직 설계.
 - Judge 신뢰도 측정 (JDG-03): 위에서 만든 Judge의 채점 결과와 사람의 정답 20건을 대조하여 일치율 산출.

[3번: 효선, 정윤] - 백엔드 조사 루프 및 대시보드 연동 (INV, STA, CHT 도메인)

- 담당 기능 ID: INV-01, INV-02, INV-03, STA-01, STA-02, CHT-01
- 사용할 데이터: (입력용) `data/processed/llm_struct_test_results.jsonl`, (조회용) `data/processed/hk_electrical_recent_full.csv`

- **To-Do:**

- **쿼리 템플릿 (INV-01):** 1.6만 건 CSV를 바탕으로 AI가 안전하게 데이터 통계를 조회할 수 있는 파이썬 조회 함수(연식 분포, 월별 추이 등 5~8종) 작성.
- **조사 루프 (INV-02, 03):** AI가 스스로 가설 수립 → 쿼리 템플릿 실행 → 결과에 따라 가설 유지/기각을 판단하는 반복(`while`) 로직 구현 및 근거 부족 시 정지하는 장치 마련.
- **상태 추적 DB (STA-01, 02):** 특정 차종의 결함이 '신규'인지 '기존 리콜 후 재발'인지 기록하고 추적하는 상태 DB(SQLite 수준) 뼈대 구축.
- **채팅 연동 (CHT-01):** 질의응답 시나리오(질문 → 구조화 → 조사 → 검수 → 답변) 파이프라인 연결.

[4번: PM] - 데이터 통합, K12 퇴감기 평가 및 리포트 (DAT, RPT, EVL 도메인)

- 담당 기능 ID: DAT-02, RPT-01, DSH-01, EVL-01, EVL-02

- **To-Do:**

- **리포트 자동 생성기 (RPT-01):** 완성된 JSON 결과를 읽어 견본 수준의 깔끔한 한국어 마크다운 리포트(출처 번호 인용 포함)로 렌더링하는 로직 구현.
- **대시보드 화면 연동 (DSH-01):** 알람 목록 클릭 시 상세 리포트로 연결되는 화면 UI(Figma) 및 기능 기획.
- **K12 시험 실행 (EVL-01):** 최종 완성된 시스템에 12개의 리콜 정답지(K12)를 넣어 AI의 선행 탐지 성능을 객관적으로 채점하는 '퇴감기 시험' 집행.



20건 독립 교차 채점 가이드 (작업 전 전원 필독)

영운님의 주관하에, 본격적인 로직 작업 전 팀원 전원이 동일한 데이터 20건을 읽고 서로 결과를 모르는 상태(블라인드)에서 직접 채점(분류)하는 과정을 거칩.

? 왜 전문가도 아닌 사람이 직접 채점(Gold Label 제작)하는가?

1. **AI 성능 평가의 기준선 수립:** 소비자의 불만 텍스트는 명확한 정답이 없는 주관적 데이터임. AI가 잘 분류했는지 평가하려면, 먼저 "인간들이 합의한 객관적인 정답 기준선(Gold Label)"을 만들어야 함. 이는 NLP(자연어 처리) 분야 시스템 구축의 표준 평가 방식임.
2. **프롬프트 룰 도출:** 서로 채점 결과가 엇갈리는 경계 케이스(Edge case)를 토론해야만, AI 프롬프트에 "이런 애매한 상황은 이렇게 채점해라"라는 명확한 룰을 심을 수 있음.
3. **AI 검사관(Judge) 신뢰도 검증:** 이후 수만 건을 채점할 AI 검사관이 제대로 작동하는지 검증하려면, '우리가 만든 정답(Gold Label)'과 'Judge가 채점한 결과'의 일치율을 대조해야만 AI를 믿고 대량 채점을 맡길 수 있음.

🛡 비전문가인데 맘대로 판정해도 되나?

우리는 자동차 전문가가 아니라 텍스트를 분류하는 데이터 엔지니어임. 비전문가로서 자의적 해석을 차단하기 위해, **자동차 기능안전 국제표준(ISO 26262)의 '통제 가능성(Controllability)' 개념**을 외부에서 차용하여 판정 규칙의 잣대로 삼음.



채점 시 적용할 핵심 3원칙 (09_판정규칙_근거자료.md 필독)

09. 판정규칙_근거자료.md

본인의 직관이 아닌 아래 룰에 따라 기계적으로 채점할 것.

1. **결함-결과 분리:** 사고 이력이 서술되어 있어도 결함 자체와 인과관계가 불분명하면 심각도에 반영하지 않음. 결함 자체가 야기하는 기능적 위험성만 판단함.
2. **통제 가능성:** 후방카메라 고장처럼 운전자가 즉시 다른 대체 수단(육안, 미러 등)으로 통제 가능하면 상한선을 **SERIOUS** 로 제한함. 제동/조향/시야 상실처럼 운전자 통제가 불가능해야 **CRITICAL** 임.
3. **오작동 > 미작동:** 브레이크가 안 밟히는 것(미작동)보다, 차량이 의도치 않게 급제동(오작동)하는 것이 운전자 입장에서 통제 불가능하므로 한 단계 더 위험한 것으로 판정함.

 **왜 직접 채점해야 하는가?**에 대한 의문이 들어 찾아본 결과 다음과 같은 학술적 이유가 존재함.

1. 순환 평가의 오류 (Circular Evaluation) 방지

- LLM이 내린 결론을 인간의 기준 없이 LLM에게 스스로 채점하게 하면, 자기 출력을 선호하는 편향(Self-Preference Bias)으로 인해 무조건 높은 점수가 나오는 착시가 발생함.
- 학술적 근거:

[Zheng et al 2023 Judging LLM as a Judge.pdf](#)

2. 프롬프트 정제와 모호성 해소 (Inter-Annotator Agreement, IAA)

- 사람마다 위험도를 다르게 판단하는 '주관성'을 잡아야 함. 팀원들이 독립적으로 채점 후 결과가 엇갈리는 사례(Edge Case)를 찾아내야만, AI 프롬프트에 "이런 애매한 상황은 이렇게 채점해라"라는 명확한 룰(Rubric)을 주입할 수 있음.
- 학술적 근거: 주관적 텍스트 분류 작업에서는 평가자 간 일치도(IAA)를 분석하여 평가 기준을 명확히 하는 것이 필수적임 (Artstein & Poesio, 2008).

[Inter Coder Agreement for Computational Linguistics.pdf](#)

3. LLM 평가관의 체계적 편향(Bias) 및 환각 통제

- 룰이 엄격하게 주입되지 않은 검사 AI(Unconstrained Judge)는 무조건 긴 답변에 높은 점수를 주거나(Verbosity Bias) 원문에 없는 카테고리를 지어내는 환각을 일으킴.
- 학술적 근거: 국제 인공지능 표준(ISO/IEC 24027:2021)은 AI 시스템 편향 관리를 위해 반드시 인간이 개입하는 'Human-in-the-loop' 검증을 권고함. 우리가 만드는 20건의 정답지가 바로 이 검증의 기준선이 될 것.

기타 참고자료:

<https://arxiv.org/html/2603.06865v1>

<https://galtea.ai/blog/llm-as-a-judge-the-complete-guide>

<https://www.zenml.io/llmops-database/llm-as-a-judge-framework-for-automated-llm-evaluation-at-scale>