

2. 데이터 소스 및 베이스라인 분석 결과

☰ 진행상황

사전준비

1. 데이터 확보 현황

- **입력 데이터 (NHTSA 소비자 불만):** 전체 222만 건 중 현대·기아차 전장/SW 관련 결함 (2022년 이후)만 필터링하여 총 **16,964건 추출 완료**.
- **정답지 데이터 (평가용 리콜 기록):** 미국 리콜 캠페인 164건, 한국 국토부 리콜 79행 수집 완료. API 통신 키 없이 전량 활용 가능.

? 입력 데이터(불만)와 정답지 데이터(리콜)는 왜 나뉘어 있는가?

- **입력 데이터 = AI가 풀 '문제지':** 일반 소비자가 "내 차 이상해요"라고 올린 미검증 텍스트임. 노이즈가 많고 주관적임. 우리 AI가 직접 읽고 결함 시그널을 찾아내야 할 분석 대상임.
- **정답지 데이터 = 채점용 '역사적 사실':** 제조사나 정부가 "이 차종에 진짜 결함이 있다"고 공식 발표한 확정 기록임.
- **어떻게 쓰는가 (되감기 시험):** 시스템 평가 시, AI에게 정답지(리콜)가 발표되기 **이전** 시점의 문제지(불만 데이터)만 제공함. 그리고 AI가 스스로 결함 징후를 알아채는지, 그 결론이 실제 역사에 기록된 정답(리콜 기록)과 정확히 일치하는지 대조하여 우리 시스템의 성능을 객관적으로 채점함.

2. 다루게 될 CSV 데이터 핵심 스키마 (입력 데이터 기준)

데이터(Raw Data)를 열어보면 51개 필드가 있지만, 우리가 주로 다룰 핵심 컬럼은 다음과 같음.

- **odiNumber** (ODINO): 불만 1건의 고유 번호. 나중에 챗봇이나 리포트에서 "출처 번호"로 인용할 때 쓰임.

- `dateComplaintFiled`: 소비자가 불만을 접수한 날짜. 위에서 설명한 '되감기 시험 (K12)'을 할 때 기준 시간표 역할을 함.
- `components`: 기존에 사람이 매겨놓은 부품 카테고리 라벨.
- `summary` (`CDESCR`): 소비자가 직접 쓴 불만 서술문 원문. 우리 AI가 직접 읽고 분석해야 할 가장 중요한 핵심 텍스트임.
- `crash`, `fire` 등: 심각도를 기계적으로 판정할 때 힌트가 되는 사고/화재 여부 플래그.

💡 확인된 팩트: 왜 일반 코딩이 아니라 AI(LLM)를 꼭 써야 하는가?

- 데이터를 까본 결과, 주행 중 차량 섀시다운 같은 심각한 위험 신호인데도 기존 부품 라벨 (`components`)에 `UNKNOWN OR OTHER` (기타)로 잘못 분류된 데이터가 전체의 30%(1,702 건)나 존재함.
- 주행거리계 사기가 '전장 결함'으로 잡히는 등 단순 키워드나 기존 라벨 집계만으로는 진짜 시그널을 절대 찾을 수 없음.
- **결론:** 기존 라벨을 무시하고, 소비자의 원문(`CDESCR`) 텍스트를 AI가 직접 읽어 문맥을 파악하는 'LLM 구조화 모듈'이 우리 파이프라인의 핵심 필수 로직임.