

I. 들어가며 - 지금까지의 수업 정리와 출발점

1. 수업에서 다룬 것 (요약)

- **LLM 기초:** Next-token prediction 원리. Context window 안의 정보만 참고 가능하며, 없는 정보는 추측(환각)으로 채움
- **Prompt Engineering:** 좋은 프롬프트 6요소 (Role·Task·Input·Constraint·Output·Criteria), 5대 패턴(Role / Constraint / Structured Output / Rubric / Uncertainty Handling)
- **Context Engineering:** 지시문을 넘어 정책·데이터·도구·이력 등 업무 맥락 전체를 슬롯 구조([Domain Policy], [Tool Rules], [Decision Criteria], [Output Schema], [Examples] 등)로 설계
- **ICL(In-Context Learning):** 3~8개 예시로 출력 안정화
- **Test-Time Scaling:** Self-Consistency(다수결), Generate-Critique-Revise, Verifier Judge, Best-of-N — 학습 없이 추론 시점에 품질 향상
- **(Day 2) 성공/실패 로그** → Instruction Data 변환 → sLLM 학습으로 이어지는 파이프라인

2. 교수님이 강조한 것 (프로젝트 가이드 기준)

1. API 호출이 목표가 아니라 문제를 푸는 구조 설계가 목표
2. 근거 있는 답 - 그럴듯한 답이 아니라
3. 모르면 모른다 - 데이터에 없는 내용을 만들지 않는 설계
4. 계산·검색·검증은 도구와 분리 - LLM은 사고·판단
5. 평가가 있어야 완성 - Baseline, test case, 실패 분석까지
6. 주제와 데이터 확보를 동시에 고민
7. 완벽한 agent보다 작은 baseline → 실패 → 개선, 수준을 낮춰서라도 완결

3. AI Agent란 무엇인가 — 용어 정리

LLM과 Agent는 다른 것:

	LLM	AI Agent
정체	다음 단어를 확률적으로 예측하는 언어 모델 (두뇌, 부품)	LLM에 도구·기억·판단 루프를 결합한 시스템 전체 (완제품)
할 수 있는 것	context 안의 정보를 읽고 추론·판단·서술	판단에 따라 도구(검색·DB 조회·코드 실행)를 선택·실행하고, 결과를 보고 다음 행동 결정
할 수 없는 것	스스로 검색·계산·실행 불가. 없는 정보는 추측(환각)으로 채움	—
작동 방식	질문 → 답변 (1회)	생각 → 도구 실행 → 결과 관찰 → 재판단 (루프)

- 교수님 정의: **LLM은 사고·판단의 주체, 실행은 도구에 위임**
- 챗봇/RAG와의 구분: 챗봇은 학습 지식으로 답변, RAG는 검색 → 요약 고정 경로 1회. Agent는 **무엇을 조회할지 스스로 판단하고, 결과에 따라 경로가 바뀜**
- 본 제안서의 Agent는 이 의미로 사용됨.

4. 훌륭한 AI Agent의 기준

위 내용을 종합하면, 좋은 Agent는 다음 6가지를 충족해야 함:

기준	의미
① 역할 분리	계산은 코드, 판단은 LLM
② 동적 경로	상황에 따라 LLM이 도구·순서를 스스로 선택 (고정 파이프라인 X)
③ 불확실성 통제	증거 부족 시 모름/보류
④ 자가 검증	생성한 답을 스스로 비판·기각하는 루프
⑤ 추적성	모든 주장에 원문 근거(Citation) — 역추적 가능
⑥ 평가 가능성	Baseline 대비 개선을 숫자로 증명할 정답지 존재

→ **이 6가지를 모두 충족할 수 있는 주제**를 찾는 것이 제안의 출발점이다.